

科学计算(Scientific Computing)

第八章 线性方程组的解法: 迭代解法

任课老师: Xiao-liang Cheng(程晓良)

Department of Mathematics, Zhejiang University, Hangzhou 310027, P.R. China.

since 2018



线性方程组的解法:迭代解法

- 1 范数
 - 向量范数
 - 矩阵范数
 - 线性方程组的敏感性与条件数

线性方程组的解法:迭代解法

1 范数

- 向量范数
- 矩阵范数
- 线性方程组的敏感性与条件数

2 迭代法

- Jacobi迭代法
- Gauss-Seidel迭代法
- 超松弛迭代法(SOR)
- 迭代法收敛条件与误差估计

线性方程组的解法:迭代解法

- ① 范数
 - 向量范数
 - 矩阵范数
 - 线性方程组的敏感性与条件数
- ② 迭代法
 - Jacobi迭代法
 - Gauss-Seidel迭代法
 - 超松弛迭代法(SOR)
 - 迭代法收敛条件与误差估计
- ③ 共轭斜量法*

向量范数

定义： 对 $x \in R^n$ 是列向量, 若实值函数 $N(x) =: \|x\|$ 满足下列关系式:

- (1) 正定性: 对所有的 $x \in R^n$ 有 $\|x\| \geq 0$, 而且 $\|x\| = 0$ 当且仅当 $x = 0$;
- (2) 齐次性: 对所有的 $x \in R^n$ 和 $\alpha \in R$ 有 $\|\alpha x\| = |\alpha| \cdot \|x\|$;
- (3) 三角不等式: 对所有的 $x, y \in R^n$ 有 $\|x + y\| \leq \|x\| + \|y\|$,
则称 $N(x) =: \|x\|$ 为 R^n 上的向量 x 的**范数**(或**模**).

最常用的向量范数是下列三个:

$$\|x\|_1 = \sum_{j=1}^n |x_j| ;$$

$$\|x\|_2 = \left(\sum_{j=1}^n |x_j|^2 \right)^{\frac{1}{2}} ;$$

$$\|x\|_\infty = \max_{1 \leq j \leq n} |x_j| .$$

它们分别称为1范数,2范数和 ∞ 范数.

在有限空间里，可以引进各种范数，但由下面的等价定理.

定理: 设 $\|\cdot\|_\alpha$ 和 $\|\cdot\|_\beta$ 是 \mathbf{R}^n 上任意两种范数，则存在正常数 C_1 和 C_2 , 使得对一切 $x \in \mathbf{R}^n$ 有

$$C_1\|x\|_\alpha \leq \|x\|_\beta \leq C_2\|x\|_\alpha.$$

可以证明常见范数之间等价的精确常数:

$$\|x\|_2 \leq \|x\|_1 \leq \sqrt{n}\|x\|_2;$$

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n}\|x\|_\infty;$$

$$\|x\|_\infty \leq \|x\|_1 \leq n\|x\|_\infty.$$

定义： 若矩阵 $A \in R^{n \times n}$ 的某个实值函数 $N(A) =: \|A\|$ 满足下列条件：

- (1) 正定性: 对所有的 $A \in R^{n \times n}$ 有 $\|A\| \geq 0$, 而且 $\|A\| = 0$ 当且仅当 $A = 0$;
 - (2) 齐次性: 对所有的 $A \in R^{n \times n}$ 和 $\alpha \in R$ 有 $\|\alpha A\| = |\alpha| \cdot \|A\|$;
 - (3) 三角不等式: 对所有的 $A, B \in R^{n \times n}$ 有 $\|A + B\| \leq \|A\| + \|B\|$;
 - (4) 相容性: 对所有的 $A, B \in R^{n \times n}$ 有 $\|AB\| \leq \|A\| \cdot \|B\|$,
- 则称 $N(A) =: \|A\|$ 为 $R^{n \times n}$ 上矩阵 A 的**范数**(或**模**).

注意到： $R^{n \times n}$ 上的矩阵范数可以看做是 R^{n^2} 上的向量范数.

矩阵范数和向量范数"协调":

$$\|Ax\| \leq \|A\| \|x\|.$$

对于向量1范数,2范数和 ∞ 范数 $\|x\|_r$, 容易验证

$$\|A\|_r = \max_{x \neq 0} \frac{\|Ax\|_r}{\|x\|_r}$$

满足矩阵定义中的(1)(2)(3)(4).

可以计算

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|;$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)};$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

对于一般的向量范数 $\|x\|$ ，我们定义

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$$

它是一个矩阵范数. 这样的矩阵范数 $\|A\|$ 称为向量范数 $\|x\|$ 的诱导范数, 或算子范数.

极限的概念: 分量意义下

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x};$$

$$\lim_{k \rightarrow \infty} A^{(k)} = A.$$

谱半径

设 $n \times n$ 阶矩阵 A 的特征值为 $\lambda_i (i = 1, 2, \dots, n)$, 则称

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$$

为矩阵 A 的谱半径.

矩阵范数和谱半径有如下关系:

$$\rho(A) \leq \|A\|.$$

利用谱半径, 矩阵2范数可写成

$$\|A\|_2 = \sqrt{\rho(A^T A)}.$$

定理:

$$\lim_{k \rightarrow \infty} A^k = 0 \iff \rho(A) < 1.$$

数据扰动的影响

方程组

$$\begin{cases} x_1 + x_2 = 2, \\ x_1 + 1.0001x_2 = 2 \end{cases}$$

的解为 $x_1 = 2, x_2 = 0$.

若系数和右端有扰动, 方程组

$$\begin{cases} x_1 + x_2 = 2, \\ x_1 + 0.9999x_2 = 1.9999 \end{cases}$$

的解为 $x_1 = 1, x_2 = 1$.

解相差很大!

估计式(I):

方程 $Ax = b$ 的右端扰动 δb , 解为 $x + \delta x$, 则

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \|A\| \frac{\|\delta b\|}{\|b\|}.$$

证明: 由于

$$Ax = b, \quad A(x + \delta x) = b + \delta b.$$

因此

$$A\delta x = \delta b, \implies \|\delta x\| \leq \|A^{-1}\| \|\delta b\|.$$

再利用

$$\|b\| = \|Ax\| \leq \|A\| \|x\|, \implies \|x\| \geq \frac{\|b\|}{\|A\|}.$$

估计式(II):

方程 $Ax = b$ 的系数矩阵扰动 δA , 解为 $x + \delta x$, 则

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \|A\| \frac{\|\delta A\|}{\|A\|}.$$

说明: 若 $\|A^{-1}\| \|\delta A\| < 1$, 则 $A + \delta A$ 非奇异. 由

$$Ax = b, \quad (A + \delta A)(x + \delta x) = b,$$

推出

$$\delta x = -A^{-1} \delta A(x + \delta x) (\approx -A^{-1} \delta A x).$$

可推出

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \|A\| \frac{\|\delta A\|}{\|A\|}}{1 - \|A^{-1}\| \|\delta A\| \frac{\|\delta A\|}{\|A\|}}.$$

条件数

数 $\|A^{-1}\| \|A\|$ 反映了方程组 $Ax = b$ 的解对初始数据 A, b 扰动的灵敏度，可用来刻画方程组的病态程度。

我们称 $\|A^{-1}\| \|A\|$ 为矩阵 A 的条件数，记作 $\text{cond}(A)$ ，即

$$\text{cond}(A) = \|A^{-1}\| \|A\|.$$

取不同的范数

$$\text{cond}(A)_{\infty} = \|A^{-1}\|_{\infty} \|A\|_{\infty}.$$

$$\text{cond}(A)_2 = \|A^{-1}\|_2 \|A\|_2 = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}}.$$

近似解可靠性判别法

什么是方程组 $Ax = b$ 的解?

假设 \hat{x} 是一个近似解, 计算残量 $r = b - A\hat{x}$. 残量越小, \hat{x} 越近似 x ?

例如. 方程组

$$\begin{cases} 0.780x_1 + 0.563x_2 = 0.217 \\ 0.913x_1 + 0.659x_2 = 0.254 \end{cases}$$

的准确解为 $x_1 = 1, x_2 = -1$.

而 $\hat{x}_1 = 0.341, \hat{x}_2 = -0.087$, 则残量 $r = (-10^{-6}, 0)^T$. 换句话说

$$\begin{cases} 0.780x_1 + 0.563x_2 = 0.217 + 10^{-6} \\ 0.913x_1 + 0.659x_2 = 0.254 \end{cases}$$

的解就是 $\hat{x}_1 = 0.341, \hat{x}_2 = -0.087$.

定理: 设 x^* 是方程组 $Ax = b$ (A 非奇异, $b \neq 0$)的精确解. 若 \hat{x} 是该方程组的近似解, 其残量 $r = b - A\hat{x}$, 则有

$$\frac{\|x^* - \hat{x}\|}{\|x^*\|} \leq \text{Cond}(A) \frac{\|r\|}{\|b\|}.$$

证明: 因为

$$\|b\| = \|Ax^*\| \leq \|A\| \|x^*\|.$$

$$\|\hat{x} - x^*\| = \|A^{-1}(A\hat{x} - b)\| \leq \|A^{-1}\| \|r\|.$$

易证.

病态方程组的一个测试例子

Hilbert矩阵: $H = (h_{ij})_{n \times n}$,

$$h_{i,j} = \frac{1}{i+j-1}.$$

例如:

- $n = 10$, $Cond(H) = 1.6025 \times 10^{13}$;
- $n = 15$, $Cond(H) = 2.6388 \times 10^{17}$;
- $n = 20$, $Cond(H) = 2.5072 \times 10^{18}$.

研究: 预条件处理方法

求解 $Ax = b$ 转化成求解 $P^{-1}Ax = P^{-1}b$ 要求

(1). $Cond(P^{-1}A) \ll Cond(A)$;

(2). 求解 $Py = d$ 比求解 $Ax = b$ 容易的多!

解线性方程组的迭代法

基本思想: 构造一个向量序列 $x^{(n)}$, 使其收敛至某个极限向量 x^* , 则 x^* 就是要求的方程组

$$Ax = b$$

的准确解.

对迭代法来说一般有几个问题:

- (1) 如何构造迭代序列?
- (2) 构造的序列在什么情况下收敛?
- (3) 如果收敛, 收敛的速率如何?
- (4) 近似解的误差估计.

Jacobi迭代法

解线性方程组 $Ax = b$. 对于第 i 个方程解出 x_i (把其它变量看作已知):

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j \right), \quad i = 1, 2, \dots, n.$$

将右边用第 k 步的值 $x^{(k)}$ 代入, 得到第 $k+1$ 步的值 $x^{(k+1)}$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n.$$

把线性方程组中的矩阵 A 记为

$$A = D - L - U$$

其中

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$L = \begin{bmatrix} 0 & & & & 0 \\ -a_{21} & 0 & & & \\ -a_{31} & -a_{32} & 0 & & \\ \vdots & \vdots & \ddots & \ddots & \\ -a_{n1} & -a_{n2} & \cdots & -a_{n,n-1} & 0 \end{bmatrix}$$

$$U = \begin{bmatrix} 0 & -a_{12} & -a_{13} & \cdots & -a_{1n} \\ & 0 & -a_{23} & \cdots & -a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & -a_{n-1,n} \\ 0 & & & & 0 \end{bmatrix}$$

则Jacobi迭代法的矩阵表示:

$$Ax = b \iff (D - L - U)x = b \iff Dx = b + (L + U)x$$

$$x = D^{-1}(b + (L + U)x) \iff x^{(k+1)} = D^{-1}b + D^{-1}(L + U)x^{(k)}.$$

即

$$x^{(k+1)} = B_J x^{(k)} + f_J, \quad (k = 0, 1, 2, \dots)$$

$$B_J = D^{-1}(L + U), \quad f_J = D^{-1}b.$$

Gauss-Seidel迭代法

解线性方程组 $Ax = b$. 对于第 i 个方程解出 x_i (把其它变量看作已知):

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j \right), \quad i = 1, 2, \dots, n.$$

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j - \sum_{j=i+1}^n a_{ij} x_j \right), \quad i = 1, 2, \dots, n.$$

将右边用第 k 步的值 $x^{(k)}$ 代入, 得到第 $k+1$ 步的值 $x^{(k+1)}$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n.$$

则Guass-Seidel迭代法的矩阵表示:

$$Ax = b \iff (D - L - U)x = b \iff Dx = b + (L + U)x$$

$$Dx = b + Lx + Ux \iff Dx^{(k+1)} = b + Lx^{(k+1)} + Ux^{(k)}.$$

即

$$x^{(k+1)} = B_G x^{(k)} + f_G, \quad (k = 0, 1, 2, \dots)$$

$$B_G = (D - L)^{-1}U, \quad f_G = (D - L)^{-1}b.$$

例子

方程组

$$\begin{cases} 10x_1 - 2x_2 - x_3 = 3, \\ -2x_1 + 10x_2 - x_3 = 15, \\ -x_1 - 2x_2 + 5x_3 = 10. \end{cases}$$

改写成

$$\begin{cases} x_1 = 0.3 + 0.2x_2 + 0.1x_3, \\ x_2 = 1.5 + 0.2x_1 + 0.1x_3, \\ x_3 = 2.0 + 0.2x_1 + 0.4x_2. \end{cases}$$

则Jacobi迭代法: 给定 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, x_3^{(0)})^T$, 对 $k = 0, 1, 2, \dots$,

$$\begin{cases} x_1^{(k+1)} = 0.3 + 0.2x_2^{(k)} + 0.1x_3^{(k)}, \\ x_2^{(k+1)} = 1.5 + 0.2x_1^{(k)} + 0.1x_3^{(k)}, \\ x_3^{(k+1)} = 2.0 + 0.2x_1^{(k)} + 0.4x_2^{(k)}. \end{cases}$$

则Gauss-Seidel迭代法: 给定 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, x_3^{(0)})^T$,
对 $k = 0, 1, 2, \dots$,

$$\begin{cases} x_1^{(k+1)} = 0.3 + 0.2x_2^{(k)} + 0.1x_3^{(k)}, \\ x_2^{(k+1)} = 1.5 + 0.2x_1^{(k+1)} + 0.1x_3^{(k)}, \\ x_3^{(k+1)} = 2.0 + 0.2x_1^{(k+1)} + 0.4x_2^{(k+1)}. \end{cases}$$

或

$$\begin{cases} x_1^{(k+1)} = 0.3 + 0.2x_2^{(k)} + 0.1x_3^{(k)}, \\ x_2^{(k+1)} = 1.56 + 0.04x_2^{(k)} + 0.12x_3^{(k)}, \\ x_3^{(k+1)} = 2.684 + 0.056x_2^{(k)} + 0.068x_3^{(k)}. \end{cases}$$

注意: 写算法程序无需这一步!下面收敛分析需要这一步!!

超松弛迭代法(SOR)

在Gauss-Seidel迭代中加入松弛因子 $\omega > 0$

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - a_{ii} x_i^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n$$

当 $\omega = 1$ 时即为Gauss-Seidel迭代法. 也可看作加权平均:

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \omega \hat{x}_i^{(k+1)}.$$

矩阵形式:

$$Dx^{(k+1)} = Dx^{(k)} + \omega(b + Lx^{(k+1)} - Dx^{(k)} + Ux^{(k)});$$

即

$$(D - \omega L)x^{(k+1)} = \omega b + (1 - \omega)Dx^{(k)} + \omega Ux^{(k)}.$$

即

$$x^{(k+1)} = B_S x^{(k)} + f_S,$$

$$B_S = (D - \omega L)^{-1}((1 - \omega)D + \omega U);$$

$$f_S = \omega(D - \omega L)^{-1}b.$$

$\omega = 1$ 即Gauss-Seidel迭代公式. 通常 $0 < \omega < 2$.

当 $1 < \omega < 2$ 称为超松弛迭代;

当 $0 < \omega < 1$ 称为低松弛迭代.

定理: 对任意初始向量 $x^{(0)}$ 和常数项 f , 由迭代格式

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, 2, \dots$$

产生的向量序列 $x^{(k)}$ 收敛且极限与初值无关的充分必要条件是

$$\rho(B) < 1$$

其中 $\rho(B)$ 是矩阵 B 的谱半径.

证明: 必要性, 收敛到 x^* , 则取极限得 $x^* = Bx^* + f$. 于是

$$x^{(k+1)} - x^* = B(x^{(k)} - x^*) = \dots = B^{k+1}(x^{(0)} - x^*).$$

对任意初始向量均收敛到零, 则 B^k 的极限是0.

充分性: 若 $\rho(B) < 1$, 则 $x = Bx + f$ 有唯一解, 记 x^* . 同理可证.

定理: 若迭代过程 $x^{(k+1)} = Bx^{(k)} + f$ 中迭代矩阵 B 的某种算子范数 $\|B\|_r = q < 1$, 则

(1) 对任意初始向量 $x^{(0)}$, 该迭代过程均收敛于方程 $x = Bx + f$ 的唯一解 x^* ;

(2)

$$\|x^* - x^{(k)}\|_r \leq \frac{1}{1 - q} \|x^{(k+1)} - x^{(k)}\|_r;$$

(3)

$$\|x^* - x^{(k)}\|_r \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|_r.$$

证明: (1) 因为 $\|B\|_r = q < 1$, 则 $\rho(B) < 1$, 因此方程 $x = Bx + f$ 存在唯一解 x^* .

又

$$\begin{aligned}x^{(k+1)} - x^* &= B(x^{(k)} - x^*), \\ \|x^{(k+1)} - x^*\|_r &\leq q \|x^{(k)} - x^*\|_r \leq q^{k+1} \|x^{(0)} - x^*\|_r.\end{aligned}$$

(2) 因为

$$\|x^{(k)} - x^*\|_r = \|x^{(k)} - x^{(k+1)} + x^{(k+1)} - x^*\|_r \leq \|x^{(k+1)} - x^{(k)}\|_r + \|x^{(k+1)} - x^*\|_r.$$

$$\|x^{(k)} - x^*\|_r \leq \|x^{(k+1)} - x^{(k)}\|_r + q \|x^{(k)} - x^*\|_r.$$

(3)

$$\begin{aligned}x^{(k+1)} - x^{(k)} &= B(x^{(k)} - x^{(k-1)}), \\ \|x^{(k+1)} - x^{(k)}\|_r &\leq q \|x^{(k)} - x^{(k-1)}\|_r.\end{aligned}$$

注意到, 迭代矩阵范数小于1是收敛的充分条件, 不是必要的.

$$\begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \end{pmatrix} = \begin{pmatrix} 0 & 2 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad k = 0, 1, 2, \dots$$

迭代矩阵 B 的 $\|B\|_1 = 2$, $\|B\|_\infty = 2$, 但迭代法收敛.

判别收敛的几个常用条件

不可约: 如果矩阵 A 不能通过行的次序的调换和相应列的次序的调换成为

$$\begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix}$$

其中 A_{11}, A_{22} 为方阵, 则称 A 不可约.

可约: 对于矩阵 A , 若存在非空指标集 S, T

$$S \cap T = \phi, \quad S \cup T = \{1, 2, \dots, n\}$$

满足

$$a_{ij} = 0, \quad i \in S, j \in T.$$

对角优势(占优): 若矩阵 $A = (a_{ij})_{n \times n}$ 满足

$$|a_{ii}| \geq \sum_{j \neq i, 1 \leq j \leq n} |a_{ij}|, \quad i = 1, 2, \dots, n$$

且至少有一个 i 使得上式中严格的不等号成立, 则称矩阵 A 具有对角优势. 特别地, 若所有 i 值上式中严格的不等号成立, 则称矩阵 A 具有**严格对角优势(占优)**.

定理: 若方程组 $Ax = b$ 的系数矩阵 A 具有严格对角优势, 即满足

$$|a_{ii}| > \sum_{j \neq i, 1 \leq j \leq n} |a_{ij}|, \quad i = 1, 2, \dots, n$$

则方程组 $Ax = b$ 有唯一解, 且对任意初始向量 $x^{(0)}$, Jacobi和Gauss-Seidel迭代法都收敛.

用 $\|\cdot\|_\infty$ 来证. 记

$$q = \max_{1 \leq i \leq n} \frac{\sum_{j \neq i, 1 \leq j \leq n} |a_{ij}|}{|a_{ii}|} < 1.$$

设 $\|x^{(k)} - x^*\|_\infty = t$, 按分量, 比如Jacobi迭代法,

$$|x_1^{(k+1)} - x_1^*| = \left| \sum_{j=2}^n \frac{a_{1j}}{a_{11}} (x_j^{(k)} - x_j^*) \right| \leq qt.$$

$$|x_i^{(k+1)} - x_i^*| = \left| \sum_{j=2}^n \frac{a_{ij}}{a_{ii}} (x_j^{(k)} - x_j^*) \right| \leq qt.$$

从而可证明: $\|x^{(k+1)} - x^*\|_\infty \leq qt$
即

$$\|x^{(k+1)} - x^*\|_\infty \leq q \|x^{(k)} - x^*\|_\infty.$$

递推可证序列 $x^{(k)}$ 收敛.

在Gauss-Seidel迭代法中, 同理通过逐个分量证明, 最后得到上面的式子.

定理: 若方程组 $Ax = b$ 的系数矩阵 A 具有对角优势且不可约, 则Jacobi迭代法必定收敛.

证明: 设迭代矩阵为 B , 则只要证明 $\rho(B) < 1$ 即可. 设 B 的特征值为 μ , 对应的特征向量为 $x = (x_1, x_2, \dots, x_n)^T$,
 $|x_p| = \max_i |x_i| > 0$, 则

$$\mu a_{ii}x_i = -\sum_{j \neq i} a_{ij}x_j, \quad i = 1, 2, \dots, n, \text{ let } i = p \implies |\mu| \leq 1.$$

若 $\mu = 1$, 则必有

$$\sum_{j \neq p} \frac{|a_{pj}|}{|a_{pp}|} = 1, \quad \frac{|x_j|}{|x_p|} = 1, \text{ when } a_{pj} \neq 0.$$

故 A 不可能具有严格对角优势. 下面说明: 若 $|\mu| = 1$, A 也不可能不可约且具有对角优势.

若 A 不可约且具有对角优势, 则那些与 p 相连($a_{pj} \neq 0$)的 j 必有 $|x_j| = |x_p|$. 将所有下标分成两个集合: 所有模为 $|x_p|$ 的指标记为 S , 其余指标集为 T , 在 T 的 j , $|x_j| < |x_p|$.

显然 T 非空, 因为具有对角优势的定义, 至少有一个 q , 有

$$|a_{qq}| > \sum_{j \neq q} |a_{qj}|$$

此时必有 $|x_q| < |x_p|$, 否则 $|x_q| = |x_p|$ 就矛盾.

于是, 存在非空集合 S, T , 有 $a_{ij} = 0, i \in S, j \in T$, 和不可约矛盾. 因此 $|\mu| < 1$.

定理: 若方程组 $Ax = b$ 的系数矩阵为对称正定矩阵, 则对任意初始向量 $x^{(0)}$, Gauss-Seidel 迭代法收敛.

证明. 设 $A = D - L - L^T$, Gauss-Seidel 迭代矩阵为 $(D - L)^{-1}L^T$.

$$(D - L)^{-1}L^T x = \lambda x.$$

则

$$L^T x = \lambda(D - L)x.$$

记 $(x, L\bar{x}) = \alpha + \beta i$, $c_0 = (Dx, \bar{x}) > 0$.

$$(Ax, \bar{x}) = (Dx, \bar{x}) - (Lx, \bar{x}) - (L^T x, \bar{x}) = c_0 - 2\alpha > 0.$$

由 $L^T x = \lambda(D - L)x$ 知,

$$|\lambda|^2 = \left| \frac{(L^T x, \bar{x})}{((D - L)x, \bar{x})} \right|^2 = \frac{\alpha^2 + \beta^2}{(c_0 - \alpha)^2 + \beta^2}.$$

$$|\lambda|^2 = \frac{\alpha^2 + \beta^2}{c_0(c_0 - 2\alpha) + \alpha^2 + \beta^2} < 1.$$

即

$$|\rho(B_G)| < 1.$$

Gauss-Seidel迭代法收敛.

关于SOR方法:

定理: 若方程组 $Ax = b$ 的系数矩阵 A 的主对角线上元素 $a_{ii} \neq 0$, 则SOR法求解方程组 $Ax = b$ 收敛的必有条件是 $0 < \omega < 2$.

证明. 计算迭代矩阵

$$B_\omega = (D - \omega L)^{-1}((1 - \omega)D + \omega U)$$

的行列式

$$|\det(B_\omega)| = (1 - \omega)^n = \lambda_1 \lambda_2 \cdots \lambda_n.$$

于是收敛

$$|1 - \omega| \leq \rho(B_\omega) < 1.$$

得到 $0 < \omega < 2$, 即收敛的必要条件.

SOR方法收敛的充分条件:

定理: 设方程组 $Ax = b$ 的系数矩阵是对称正定矩阵, 且 $0 < \omega < 2$, 则对任意初始值向量 $x^{(0)}$, SOR方法收敛.

定理: 设方程组 $Ax = b$ 的系数矩阵为严格对角占优矩阵, 且 $0 < \omega < 1$, 则对任意初始值向量 $x^{(0)}$, SOR方法收敛.

使松弛法收敛最快的松弛因子叫最优松弛因子, 记为 ω_{opt} . 可以讨论最优松弛因子的选取问题. 比如 A 对称正定矩阵, 特征值在 $[\alpha, \beta]$ 之间, 则迭代法

$$x^{(k+1)} = x^{(k)} - \omega(Ax^{(k)} - b), \quad k = 0, 1, 2, \dots$$

的最优松弛因子是 $\omega_{opt} = \frac{2}{\alpha + \beta}$.

分块矩阵的迭代格式

例. 设 A, B 是 n 阶矩阵, A 非奇异. 考虑如下方程组

$$\begin{cases} Ax + By = b_1 \\ Bx + Ay = b_2 \end{cases}$$

求证: 若 $\rho(A^{-1}B) < 1$, 则下列迭代格式(块Jacobi迭代)

$$\begin{cases} Ax^{(k+1)} = b_1 - By^{(k)} \\ Ay^{(k+1)} = b_2 - Bx^{(k)} \end{cases}$$

显然迭代矩阵

$$C = \begin{pmatrix} 0 & -A^{-1}B \\ -A^{-1}B & 0 \end{pmatrix}, \begin{pmatrix} x^{(k+1)} \\ y^{(k+1)} \end{pmatrix} = C \begin{pmatrix} x^{(k)} \\ y^{(k)} \end{pmatrix} + \begin{pmatrix} A^{-1}b_1 \\ A^{-1}b_2 \end{pmatrix}.$$

设矩阵 C 的特征值为 λ , 对应特征向量 $(z_1, z_2)^T$, 则

$$A^{-1}Bz_2 = (-\lambda)z_1, \quad A^{-1}Bz_1 = (-\lambda)z_2.$$

如果 $z_1 = z_2$, 则 $(-\lambda)$ 就是 $A^{-1}B$ 的特征值(注意 $z_1 = z_2 \neq 0$);

如果 $z_1 \neq z_2$, 则

$$A^{-1}B(z_1 - z_2) = \lambda(z_1 - z_2)$$

这说明 λ 一定是 $A^{-1}B$ 的特征值. 因此当 $\rho(A^{-1}B) < 1$ 时, 推出 $|\lambda(C)| < 1$. 因此块Jacobi迭代格式收敛.

收敛速度

单步法(Jacobi迭代法, Gauss-Seidel迭代法等)收敛, 其极限 x^* 比满足

$$x^* = Mx^* + g.$$

误差 $y_k = x^{(k)} - x^*$ 就满足

$$y_k = My_{k-1} = \cdots = M^k y_0,$$

从而

$$\|y_k\| \leq \|M^k\| \cdot \|y_0\|.$$

因为初始误差未知, 用 $\|M^k\|$ 来刻画.

设 M 是单步线性迭代的迭代矩阵, 则称

$$R(M^k) = R_k(M) = \frac{-\ln\|M^k\|}{k} (= -\ln\|M^k\|^{\frac{1}{k}})$$

为 k 次迭代的平均收敛速度.

记

$$R_{\infty}(M) = \lim_{k \rightarrow \infty} R_k(M)$$

称为渐进收敛速率.

定理: 设单步线性定常迭代矩阵为 M , 则有

$$\lim_{k \rightarrow \infty} R_k(M) = -\ln \rho(M).$$

只要证明: $\lim_{k \rightarrow \infty} \|M^k\|^{\frac{1}{k}} = \rho(M)$ 即可.

共轭斜量法*

共轭斜量法(CG)是一种非线性迭代法,适用于方程组系数矩阵是实对称正定矩阵的情况. 理论上,它是直接法,至多 n (矩阵阶数)步能得到准确解,但实际上只是用做迭代法解大型稀疏方程组.

命题: 二次函数

$$H(x) = \frac{1}{2}x^T Ax - b^T x$$

极小点 x^* 当且仅当 x^* 是线性方程组

$$Ax = b$$

的解.

证明: " \implies ", 只要 $H(x)$ 求极值, 求导数, 二阶导数矩阵正定, 易得.

" \impliedby " 计算

$$H(x) = H(x^* + (x - x^*)) = H(x^*) + \frac{1}{2}(x - x^*)^T A(x - x^*) \geq H(x^*).$$

线搜索算法: 设向量 p 是给定的方向, 已知 \hat{x} , 在 $\hat{x} + tp$ 上寻找一个新的点, \tilde{x} , 使得

$$H(\tilde{x}) \leq H(\hat{x} + tp), \forall t \in R.$$

容易得到

$$\tilde{x} = \hat{x} + \frac{(b - A\hat{x}, p)}{(p, p)} p.$$

最速下降法: 选取方向向量 p 为负梯度方向, 即

$$p = b - A\hat{x}.$$

这是非线性一般问题求最值问题的算法, 我们在第十章讨论.

任取初值 x_0 , 其剩余量 $r_0 = b - Ax_0$. 可沿某个方向, 比如 $p_0 = r_0$, 求下一个近似值 $x_1 = x_0 + \alpha_0 p_0$, 可以要求新的剩余向量 $r_1 = b - Ax_1 = r_0 - \alpha_0 Ap_0$ 与 p_0 正交, 有

$$\alpha_0 = \frac{(r_0, p_0)}{(Ap_0, p_0)}.$$

再从 x_1 出发, 沿着搜索方向 p_1 找 x_2 , $x_2 = x_1 + \alpha_1 p_1$. 要求搜索方向 p_1 与 p_0 是 A 正交的, 即

$$(Ap_0, p_1) = 0.$$

即

$$p_1 = r_1 - \beta_0 p_0, \quad \beta_0 = \frac{(r_1, Ap_0)}{(p_0, Ap_0)}.$$

求 x_2 还要求 r_2 与 p_1 正交. 如此继续, 可得如下算法.

算法: 共轭斜量法

任取 x_0 , 计算 $r_0 = b - Ax_0$, $p_0 = r_0$.

对于 $k = 0, 1, 2, \dots$, 计算

$$\alpha_k = \frac{(r_k, p_k)}{(Ap_k, p_k)};$$

$$x_{k+1} = x_k + \alpha_k p_k;$$

$$r_{k+1} = b - Ax_{k+1} = r_k - \alpha_k Ap_k;$$

若 $r_{k+1} = 0$, 则停止计算;

$$\beta_k = \frac{(r_{k+1}, Ap_k)}{(p_k, Ap_k)};$$

$$p_{k+1} = r_{k+1} - \beta_k p_k.$$

算法 $r_{k+1} = 0$ 停止时, x_{k+1} 为准确解.

定理: 只要 $r_k \neq 0$, 上述算法可继续, 直到 $r_l = 0, l \leq n$. 对 $k \leq l$, 由 $r_0, Ar_0, \dots, A^{k-1}r_0$ 张成的线性子空间, 所谓Krylov子空间

$$V_k = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$$

有正交基

$$r_0, r_1, \dots, r_{k-1}, (r_i, r_j) = 0, i \neq j$$

和 A 正交基

$$p_0, p_1, \dots, p_{k-1}, (Ap_i, p_j) = 0, i \neq j$$

它们之间有关系

$$(r_j, p_i) = 0, i < j, (r_j, p_j) = (r_j, r_j).$$

算法': 共轭斜量法

任取 x_0 , 计算 $r_0 = b - Ax_0$, $p_0 = r_0$.

对于 $k = 0, 1, 2, \dots$, 计算

$$\alpha_k = \frac{(r_k, r_k)}{(Ap_k, p_k)};$$

$$x_{k+1} = x_k + \alpha_k p_k;$$

$$r_{k+1} = b - Ax_{k+1} = r_k - \alpha_k Ap_k;$$

若 $r_{k+1} = 0$, 则停止计算;

$$\beta_k = \frac{(r_{k+1}, r_{k+1})}{(r_k, r_k)};$$

$$p_{k+1} = r_{k+1} + \beta_k p_k.$$

算法 $r_{k+1} = 0$ 停止时, x_{k+1} 为准确解.

引进范数

$$\|x\|_A = (Ax, x)^{\frac{1}{2}}.$$

定理: 设 $Ax^* = b$, A 是实对称正定矩阵, 则共轭斜量法迭代序列 x_0, x_1, \dots 有下述极小性质

$$\|x^* - x_k\|_A = \min_{x \in x_0 + V_k} \|x^* - x\|_A.$$

事实上, x_k 也是函数 $H(x)$ 在 $x_0 + V_k$ 上的最小点值.